

14 - B1S

Relatório Final

EQUIPE: AAAS

Explicação nome: O nome representa um dos marcos de Inovação Científica do Brasil. Além disso, há a importância Social do Voo, representando o alcance a novos horizontes, e a quebra de barreiras geográficas. Dito isso, o robô tem o viés de lançar aos céus uma estratégia inovadora sobre a representação do Mercado Financeiro Brasileiro.

Explicação lógica da Estratégia: A estratégia consiste em 3 etapas: Mineração de Dados, Processamento e Previsão. A mineração ocorre por meio de dados governamentais, contábeis e das publicações abertas em redes sociais, de modo que o robô consiga obter informações sobre a situação atual das empresas selecionadas. O processamento envolve tanto a engenharia de dados como a seleção dos dados mais explicativos, de modo a obter uma informação mais precisa. Por fim, a previsão busca encontrar o sinal (+ ou -) do retorno diário de cada uma das empresas selecionadas, de modo a conseguir, diariamente, lucro em cima da performance do papel.

Tipo estratégia: Trade

Classe de Ativos: Ações


Universo: Ibov

Média de Trades p/ mês: 84

Holding Period: 1 Dia

Plataforma: Python, R

Benchmark: IBOV



1. Contexto

O mercado de capitais é um ambiente extremamente competitivo, cujos fatores que o influenciam são pautados em relações humanas, projeções, e conflitos de interesse. Desde o início da criação da Bolsa de Valores, investidores cuja estratégia foi pautada na análise Fundamentalista — escolha de boas empresas e assimetrias na relação Preço e Valor — se sobressaíram em intervalos de tempo longos.


A **Análise Quantitativa** vem se tornando cada vez mais importante, à medida que a quantidade de dados aumentam exponencialmente. Diariamente, Investidores (pessoa física e institucionais) tem se pautado de meios comunicação e de informação não tradicionais na construção de novas teses. A quantidade de dados expostos publicamente na internet pode servir de pilar para estratégias mais complexas envolvendo desde o **fator emocional humano** nas decisões de compra e venda até a **precificação de ativos por meio de Dados Contábeis, Fatores e Séries Temporais**.

E assim nasceu nossa estratégia, cujo principal objetivo permeia a **predição dos retornos diários de papéis** a partir da **seleção dinâmica de parâmetros** de um conjunto grande de dados contendo a **classificação dos sentimentos humanos** em redes sociais (Twitter) a respeito do papel, **dados históricos do Balanço Trimestral, dados históricos de commodities** relacionadas ao papel e um **Cálculo da Série Temporal**.


O modelo utiliza redes neurais para fazer a escolha dos parâmetros que mais influenciarão no preço dos ativos selecionados, tais **parâmetros são dinamicamente alterados à medida que o modelo aprende**.

Foram escolhidos 4 papéis: **ITSA4, PETR4, ABEV3, VALE3**, uma vez que estes se encontram entre os de maior volume negociado diariamente, e são frequentemente palco de discussões e comentários no twitter, facilitando a captura de dados para o modelo. **O principal objetivo do Robô** é no **auxílio da tomada de decisões de Curto Prazo**, seja para entrada e saída dos papéis, ou para uma **estratégia com negociações diárias**.

Nossa principal tese principal de investimento é que os movimentos de mercado podem ser explicados pelas informações disponíveis dos seus players. Dentre os principais formadores de mercado, separamos **três eixos de análise — o Investidor, a Empresa e o Governo**. As informações públicas disponíveis para cada um são posteriormente juntadas no **modelo de Machine Learning final**, no qual são feitas as previsões necessárias para realizar os trades que balanceiam o portfólio a cada intervalo de tempo pré determinado.



"Facts only account for 10% of the reactions on the stock market; everything else is psychology." - **André Kostolany**



2. Obtenção dos dados

a. Dados das pessoas

Pensamos na persona do Investidor como o melhor proxy para os movimentos de curto prazo do mercado — afinal, é ele quem realmente toma a decisão de investimento, seja positiva seja negativa. Ainda, com a ascensão comunidades privadas, plataformas para investidores e perfis no Twitter, diversas personalidades tornaram-se relevantes, gerando pequenas perturbações momentâneas nos preços. No nosso modelo, para cada ação target, fazemos **análise de sentimentos** de uma série de tweets desse público na véspera do trade, com intuito de estimar a agitação do mercado na visão da Pessoa Física. O modelo utilizado para a análise de sentimento é a [FinBERT](#), modelo de Redes Neurais Recorrentes de 2020 que apresenta acurácia superior a 85% na identificação do sentimento de textos relacionados ao mercado financeiro.

Um desafio enfrentado para a confecção dessa etapa de análise de sentimentos dos tweets foi o fato da FinBERT ser treinada para **textos em inglês**, ao contrário da situação dos comentários das ações alvo. Para tanto, foi utilizado o **serviço do Google Tradutor** como meio campo entre os textos dos tweets e a análise de sentimentos da Rede Neural. Cabe ressaltar que, embora fosse esperada uma queda considerável na acurácia da Rede Neural, tendo em vista que o tradutor acrescenta mais chances de erro, a análise de sentimentos por meio da **FinBERT continuou precisa e operante** da forma que era necessária.

Assim, foram minerados todos os tweets que citam as 4 empresas-alvo no período entre 2015 e 2019, totalizando **302555 tweets** que continham essas palavras chave e foram analisados pela FinBERT. Além disso, vendo o poder que esses dados tinham, decidimos minerar de forma equivalente, mas separadamente, **os tweets de pessoas influentes no Mercado Financeiro** que foram escolhidas por meio de premiações feitas em perfis como [@scharlab](#) e [artigos](#) da Infomoney acerca de contas para se seguir. Das **858 contas** devidamente filtradas e denotadas como influentes, foram extraídos **16159 tweets** nesse mesmo período de tempo para complementar nossa análise de dados.

b. Dados das empresas e do Governo Federal

Por outro lado, os dados referentes à **Empresa e ao Governo** foram idealizados como proxies de movimentos de **longo prazo do mercado**. Isso faz sentido porque as informações de balanço e de índices públicos de preço apresentam baixa volatilidade na janela diária em comparação com as variações trimestrais ou anuais. Para esses agentes, tomamos as informações históricas direto do **terminal da Bloomberg** (no caso dos balanços das empresas) e de **fontes oficiais do governo na internet, como o Banco Central e o IBGE**.

Com esses dados, montamos a série de indicadores tradicionais já explorados pela **análise fundamentalista** — margem, EBIT, EBITDA, lucro líquido, ROE, fluxo CAPEX, juro futuro, overnight. Exploramos também a série histórica de preços de commodities para contemplar indicadores para Petrobrás e Vale.

c. Dados adicionais

Embora o nome adicionais sugira uma menor importância, definitivamente não é o caso. Para essa última coleta de dados, foram pegos dados históricos das ações na biblioteca [Yahoo Finance](#) e, a partir desse grande volume de informações, foi possível fazer simulações estocásticas¹ para os valores dos ativos nos dias posteriores, a fim de gerar mais informação de qualidade e, por fim, utilizando o módulo [pandas ta](#), foram gerados dados de indicadores técnicos das séries temporais analisadas com o mesmo objetivo. Entre esses indicadores técnicos, temos indicadores de Volatilidade, e Tendência que trazem mais robustez ao modelo final.


Finalizando toda essa mineração de dados e a unificação de tudo em um único Dataset (um para cada ação analisada), foi obtido um DataFrame do Pandas com formato **(1461, 1136)**, isto é, uma “planilha” com **1.629.696 células**!

d. Seleção dos dados


Como o dataset possuía muitas colunas (dos mais variados tipos), foi necessário fazer uma boa limpeza com métodos de limpeza simples antes de utilizar métodos mais sofisticados para a seleção desses dados. Com isso em mente, foram feitas, na seguinte ordem: limpeza das features constantes e quase constantes, limpeza de features com muitos dados faltantes e também altamente correlacionadas com outras features.

Já com o dataset muito menor, agora com 166 colunas, optamos por fazer uma última seleção dessas colunas, visto que, com esse número de colunas, a Rede Neural possui grande tendência a Overfitting. Para esse último passo, foi feita uma busca exaustiva da seguinte forma: coluna por coluna do nosso dataset, foi treinado e aplicado um modelo [SARIMAX](#) com a série temporal da ação utilizando cada coluna, uma de cada vez, como variável exógena. Assim, após percorrer todas as colunas, foi possível ordenar as performances dessa busca exaustiva e selecionar somente as 10 variáveis de maior poder preditivo das séries temporais. O gráfico que ilustra a performance dessa busca pode ser conferido na figura

Ranking das features por F1-score



Retornos Simulados Estocasticamente pela 14-Bis via Movimento Browniano



Retornos simulação estocástica¹

Feature Selecionada	Descrição
Target (Close[t]/Close[t-1]) IBX	Previsão de movimento entre o fechamento de T com T-1. 1's para retornos positivos e 0's para retornos negativos
Max Return (Close[t]/Open[t]) Oil	Valor máximo de retorno possível do Petróleo calculado pelo modelo utilizando simulações Monte Carlo
Max Return (Open[t]/Close[t-1]) IBX	Valor máximo de retorno possível do índice IBX calculado pelo modelo utilizando simulações Monte Carlo
SQZPRO_ON_NARROW Dolar	Squeeze Pro Indicator do Dolar
Target (Close[t]/Open[t]) IBX	Cálculo do sentido do retorno intraday, 1's para retornos positivos e 0's para retornos negativos
Target (Open[t]/Open[t-1]) IBX	Previsão do sentido do retorno da abertura do dia t-1 para a abertura do dia t, 1's para retornos positivos e 0's para retornos negativos
TRUERANGE_1 IBX	Average True Range do IBX
DPO_20	Detrended Price Oscillator de 20 dias
Log-Return (Open[t]/Close[t-1]) IBX	Retorno real (Logaritmico) do
Target (Close[t]/Open[t]) Oil	Previsão do sentido do retorno intraday (abertura á fechamento do dia t) para o Petróleo

Tabela de features escolhidas

Assim, as **10** features consideradas mais preditivas encontram-se na tabela acima com as respectivas descrições para o caso do ativo **PETR4**, o resultado foi o apresentado na tabela. Observe que os retornos do preço do Barril de Petróleo foram selecionados automaticamente.


3. Criando o modelo

a. Regra de investimento

A regra de investimento utilizada foi a seguinte. Em cada dia útil, no leilão de abertura, tomamos todo o conjunto de dados já tratados e utilizamos um modelo de Redes Neurais Recorrentes previamente treinado para fazer uma previsão para esse dia: se a ação em questão sobe ou desce. Com base nessa decisão escolhemos fazer long ou short no papel. No leilão de fechamento do mesmo dia, encerramos a posição aberta. Assim, **sempre passamos a noite "zerado"**. Os pesos de cada ação no portfólio completo (das quatro ações) é otimizado pelo modelo de Treynor-Black a partir dos retornos da série temporal dos últimos dias — respeitando a decisão inicial de fazer Long ou Short no papel.

Adicionalmente, por se tratar de um modelo de Daytrade, naturalmente a volatilidade da estratégia atinge patamares altos, nesse sentido, adicionamos um papel Risk Free (100% CDI) para entrar no modelo quando a volatilidade bate **40%**.


Organograma do Modelo




Valor dos Títulos da VALE e Popularidade da Empresa com Medidas Criadas



Poder de predição da FinBERT utilizando dados do Twitter sobre as ações.




Organograma da Rede Neural utilizada pelo modelo




b. Treinamento e Backtest

Uma das principais preocupações que você, leitor, deve estar pensando é: como essa estratégia, aparentemente black-box, vai me dar dinheiro? Afinal, a robustez de um modelo em redes neurais é proporcional ao volume de dados consultados e utilizados para treinamento, enquanto a confiabilidade é ligada ao número de testes feitos em dados inéditos. Em síntese: como conciliar esses dois fatores?

Para resolver esse problema, fizemos o treinamento da rede neural em blocos. Dividimos os dados de 2015 a 2019 em **duas partes**: de **2015 a 2018 para treinamento e validação**, e de **2018 a 2019 para teste**. Nos dados de treinamento, utilizamos os dados de alguns meses consecutivos como treinamento e fazemos a previsão do trade para o próximo mês (que ainda não foi visto pelo modelo). A previsão para o mês é utilizada para avaliação do desempenho do modelo. Em seguida, esse mês é incorporado nos dados de treinamento, e é feita mais uma rodada de treinamento e previsão para o próximo mês. Esse processo é realizado até que toda a série temporal de treinamento/validação seja consumida.




Ainda vale citar que a Rede Neural final foi treinada com um limite de 600 iterações de treinamento, podendo interromper, automaticamente, o treinamento no momento em que aumentar a tendência de Overfitting. O gráfico do aprendizado em função do número de épocas é exposto a seguir.



c. Resultados dos Backtests


Nos gráficos desta seção, temos o desempenho do modelo de **2015 a 2018** para as quatro ações escolhidas. É importante frisar que, no momento do teste de um mês em específico, o modelo ainda não tinha sido treinado com os dados daquele mês, assim, é esperado que o modelo tenha performance melhor com o passar do tempo, na ideia de **Reinforcement Learning** e, mesmo que no final do processo toda a série seja consumida, o teste é feito sempre antes do treinamento incorporar o dado.

Desempenho 14-Bis no Período de Testes




Beta, Volatilidade e Sharpe como funções do tempo, em dias

Retorno Esperado por Risco para um Dia de Trabalho da 14-Bis



Retornos e Pesos Dados em Cada Dia pela 14-Bis




Nesse gráfico, na qual o eixo x é compartilhado, igual ao tempo, conseguimos ver como a 14-Bis escolheu os pesos de cada ação no decorrer do tempo e analisar o retorno comparando-o aos retornos das Redes Neurais aplicadas em cada uma das ações. Um ponto interessante de ser destacado são os períodos imprevisíveis de queda como a greve dos caminhoneiros em 2018 e o desastre da barragem de Brumadinho em que a 14-Bis praticamente anulou os pesos das ações de PETR4 e VALE4. O retorno, a partir de 2019, com mais dados de treinamento, começa a subir com mais consistência.

4. Conclusão

Por fim, vemos que R\$1000,00 investidos no início de 2018 se tornam R\$1239,00 com volatilidade média de 16% ao final de 2019, enquanto a tendência de crescimento tende a se intensificar com o passar do tempo, visto que mais dados serão utilizados para aprendizado. Além disso, é verificada uma certa segurança do modelo, porque, embora estejamos fazendo trades diários, esses trades são divididos em 4 ativos e balanceados com posições de renda fixa. Em períodos críticos para um dos papéis, é esperado que o robô diminua o peso desse papel dentro do portfólio, como aconteceu com as duas crises supracitadas.

Mesmo com um mercado de ações baseado em estratégias majoritariamente de viés fundamentalista — pautadas, em modelo de valuation sólidos como Fluxo de Caixa Descontado, comparação setorial e dividendos descontados — o grupo conseguiu modelar uma estratégia essencialmente quantitativa que se demonstrou ganhadora nos testes realizados. Dessa forma, embora essa abordagem seja não tradicional e seja repleta de estereótipos dentro do mercado financeiro, o grupo como um todo investiria no modelo criado.




Referências:

[FinBERT](#)

[@scharlab](#)

[Yahoo Finance](#)

[pandas ta](#)



Infomoney. **As 30 contas no Twitter que todo investidor deve seguir em 2017**, 24/01/2017. Disponível em <<https://www.infomoney.com.br/mercados/as-30-contas-no-twitter-que-todo-investidor-deve-seguir-em-2017/>>

CORY, Mitchell. **Detrended Price Oscillator (DPO)**, 22/07/2021. Disponível em <<https://www.investopedia.com/terms/d/detrended-price-oscillator-dpo.asp>>

ADAM, Hayes. **Average True Range (ATR)**, 29/04/2021. Disponível em <<https://www.investopedia.com/terms/a/atr.asp>>

Jinghua Zhao, Dalin Zeng, Shuang Liang, Huilin Kang, Qinming Liu. **Prediction model for stock price trend based on recurrent neural network**,. 30/04/2020

Edwin J Elton, Martin J Gruber. **Modern portfolio theory, 1950 to date**, Journal of Banking & Finance, Volume 21, Issues 11–12, 1997, Pages 1743–1759, ISSN 0378-4266,

Redes Neurais Recorrentes. 12/09/2017. Disponível em <<https://matheusfacure.github.io/2017/09/12/rnn/>>