

DESAFIO2023

Itaú Asset Quantamental



Robô
OCELLUS

EQUIPE
DESTAQUE



Itaú Quantamental

Ocellus Project

2023



DESIGN



NOME DO ROBÔ

OCELLUS

EXPLICAÇÃO DO NOME

O nome Ocellus vem do latim "ocellus", que significa "olhinho" ou "olho pequeno". Este nome foi dado aos olhos simples de insetos e outros invertebrados porque eles se assemelham a olhos humanos em miniatura. Dado que nossa estratégia analisa milhares de notícias numa rápida frequência as interpretando como humanos com pequenos olhos, escolhemos esse nome para o nosso robô. Ocellus: um pequeno olho com uma grande visão.

EXPLICAÇÃO DA LÓGICA DA ESTRATÉGIA

A estratégia consiste na extração, por meio de uma base Eikon, de headlines de notícias correlacionadas com o real, ao haver tal extração, há a computação, por meio de diferentes módulos em python, de um índice de sentimento do artigo, que traduzirá as expectativas de impacto de tal notícia sobre o mercado, a partir desse indicador é realizado uma operação de compra em dólar caso este seja positivo, ou seja, sentimento positivo computado para a headline da notícia, ou uma operação de venda em dólar caso este seja negativo, partindo do pressuposto de influência das notícias sobre investidores, e o quanto elas podem confundir o real valor da moeda nacional. Sendo tais indicadores utilizados para maior otimização da estratégia com seu uso em algoritmos de Machine Learning e iterações diversas

TIPO DE ESTRATÉGIA

Trade

CLASSE DE ATIVOS

Derivativos de Moeda

UNIVERSO

Contrato Futuro de Dólar (Com enfoque sobre o Mini-Dólar).

MÉDIA TRADES POR MÊS

6.68 Trades por Mês, sendo 107 no total. Deste, 56 Operações de Venda e 51 Operações de Compra

HOLDING PERIOD

Em média 3.54 Dias para Operações de Compra, sendo que 39.9% do tempo o sistema esteve comprado, e 3.74 Dias para Operações de Venda, sendo que 61.1% do tempo o sistema esteve vendido.

QUAL PLATAFORMA TESTOU A ESTRATÉGIA

Python

BENCHMARK DA ESTRATÉGIA

Taxa CDI

Introduzindo a Estratégia

O fundamento de nossa estratégia é o entendimento acerca da existente correlação entre o Dólar Futuro frente ao Real e a disseminação de informações no mercado. Além disso, a ciência acerca da eficiência na incorporação de informações relevantes à cotação do Dólar frente a outras moedas, partindo da Hipótese de Mercados Eficientes (EMH) é fundamental para a lógica de nossa estratégia. Dessa forma, operamos a sensibilidade dos investidores quanto às notícias voltadas ao Real como uma forma de gerar *alpha* em nosso portfólio.

Observamos que, em grande maioria, de acordo com artigos acadêmicos acerca do tema, as notícias relacionadas à macroeconomia surtiram maior efeito de variação do dólar em função de diversas moedas além do real (Untara, Toto S., Titi L. 2010)¹ (Galati 2001)⁶. Sem dúvidas, resultados que são sintoma de uma economia global interconectada, com rápido acesso à informação e alta capacidade de alocação em capital, tanto em volume quanto em velocidade.

Além disso, ao utilizar as notícias acerca do Real, ao invés de modelagens preditivas em função de variáveis econômicas, conseguimos captar sentimentos dos agentes do mercado que nem sempre vem em linha com o significado do dado disponível no momento. Essa realidade surge por conta da incorporação de expectativas futuras dos agentes ao lerem os dados mais recentes, julgando-os positivos ou negativos de acordo com suas projeções futuras ou como enxergam esse dado, o que se traduz no sentimento das notícias estando em linha com a narrativa do agente. Dessa forma, consideramos também que nossa estratégia é capaz de proteger o capital alocado dado o aumento de volatilidade que as notícias trazem aos mercados (Laakkonen 2004)². Isso se dá através da alocação em Mini Dólar em função do patamar que nosso modelo julga como ideal em função dos sinais emitidos pelo sentimento das notícias. Podemos justificar esse aumento por (i) diferentes “triggers” ativados nos agentes heterogêneos (Admati e Pfleiderer 1988)³, (ii) escolhas psicológicas (Veronesi 1999)⁵ e (iii) diferentes estratégias de previsão e análise dos impactos de novas informações na taxa de câmbio (Damodaran 1985)⁴. Podemos considerar que nossa estratégia é capaz de se comportar de forma independente à narrativas vigentes dada a forma que opera em função do sentimento das notícias, fato que pode ser observado pela matriz de correlação evidenciada mais a frente.

Notavelmente, existem diferentes tipos de informações que circulam nas notícias, dessa forma, sendo possível categorizá-las como apresentado na Figura 1. Sem dúvidas, a interpretação de cada uma delas é imprescindível para compreender a movimentação da cotação do Dólar frente a outras moedas. Entretanto, acreditamos que, em relação à absorção de informações de nossa estratégia, entendemos que notícias relacionadas ao Real são suficientes para estabelecer uma relação entre a notícia e a cotação, dado que incorporam todos os fatores que o influenciam ao levá-los em consideração na análise.

Nesse sentido, devemos considerar também a inevitabilidade da repetição de notícias acerca de determinada informação nova a ser considerada na cotação do Real frente ao Dólar. No estudo de Helina Laakkonen² é observado que notícias ressoantes também influenciaram na cotação, mais ainda se o sentimento delas for conflitante. Auxiliando nossa análise de notícias ao permitir que não necessariamente tenhamos que avaliar apenas a primeira notícia acerca do tema mas também permitindo que sejam consideradas opiniões divergentes, geradoras de volatilidade, o que permite uma percepção mais aguçada sobre as narrativas de mercado acerca das informações novas.

Figura 1: Classificação dos temas de notícias que influenciam o Real e seu impacto




Elaboração própria

NLP e Pacote Vader

O pacote Vader para Python é uma ferramenta poderosa e amplamente utilizada para análise de sentimentos em texto. Desenvolvido por C.J. Hutto, o pacote Vader (Valence Aware Dictionary and sEntiment Reasoner) emprega um léxico pré-construído que contém palavras e frases classificadas com polaridades de sentimentos. O funcionamento do pacote Vader é intuitivo, permitindo aos usuários analisar textos em busca de sentimentos positivos, negativos e neutros, além de fornecer um valor composto que representa o sentimento geral do texto. Uma característica única do Vader é sua capacidade de lidar com nuances, como o reconhecimento de sarcasmo e ambiguidade, tornando-o uma escolha popular para análise de sentimentos em mídias sociais, pesquisas de mercado e muito mais.

O funcionamento do pacote Vader baseia-se na atribuição de pontuações de sentimento a palavras e frases no texto, levando em consideração palavras em letras maiúsculas, pontuação e até mesmo emojis. A pontuação composta resultante é uma medida agregada do sentimento do texto, variando de -1 (muito negativo) a +1 (muito positivo). O Vader também fornece informações sobre sentimentos positivos, negativos e neutros em forma de pontuações separadas. Sua facilidade de uso, alta precisão e capacidade de lidar com a complexidade da linguagem natural o tornam uma escolha valiosa para a análise de sentimentos em uma ampla gama de aplicações, contribuindo significativamente para a compreensão e interpretação de dados textuais em Python.

Treinamento



Previsão



Lógica da Estratégia

A lógica por trás da nossa estratégia de investimento, parte do pressuposto antes comentado da influência das notícias sobre a expectativa dos investidores. Ao compreendermos o impacto de tais pensamentos sobre os retornos, percebemos o viés de compra ou venda de acordo com notícias nacionais sobre moeda, no entanto, esses vieses podem comprometer a visão do investidor e abrir espaço para o uso de operações contrárias para a geração de *alpha*, assim, operamos contra o mercado sobre o contrato futuro de dólar sobre real, de acordo com o sentimento das notícias sobre o real, como uma estratégia do tipo *reversal-momentum*.


De posse de mais de 5000 *headlines* de notícias sobre o real, angariadas mediante o uso de uma base Eikon, computamos em python sobre cada uma destas, seus indicadores de sentimento positivo, negativo, neutro e total. Antes, fazemos uma limpeza dos dados das notícias, os normalizando para tirar quaisquer caracteres indesejados, como tais notícias são feitas em diferentes momentos do dia, computamos os indicadores médios para cada dia, usando das diferentes notícias ali presentes.

text	sourceCode	norm	pos	neg	neu
------	------------	------	-----	-----	-----



Created

2-06-06	MERCADOS EMERGENTES-Ativos latino-americanos a...	NS:RTRS	mercados emergentesativos latinoamericanos aba...	0.0	0.0	100.0
2-06-06	EMERGING MARKETS-Latam FX, stocks shed early g...	NS:RTRS	emerging marketslatam fx stocks shed early gai...	21.1	0.0	78.9
2-06-06	MERCADOS EMERGENTES-Peso mexicano abandona alt...	NS:RTRS	mercados emergentespeso mexicano abandona alta...	0.0	14.5	85.5
2-06-06	EMERGING MARKETS-Mexican peso rises after week...	NS:RTRS	emerging marketsmexican peso rises after weeke...	16.5	0.0	83.5
2-06-07	MERCADOS EMERGENTES-Moedas depreciam em dia in...	NS:RTRS	mercados emergentesmoedas depreciam em dia ins...	0.0	16.7	83.3

tal contrato quando o sentimento total das notícias sobre o real estiver negativo, ou seja, sobre a ocorrência de um movimento oposto ao citado, sendo importante falar que fechamos nossa posição e tomamos uma nova quando da mudança de rumo dos indicadores e que tomamos tais posições em um dia posterior a tal movimento, justamente para prevenir o chamado *look-ahead bias*. Nosso objetivo principal sobre essa posição é angariar o efeito inesperado das notícias sobre o mercado, já que notícias boas e más podem influenciar e inflar a precificação de ativos, ainda mais se considerarmos a tendência humana de pânico mediante certas informações. **Com tal estratégia obtivemos os seguintes retornos e Sharpe:**



Backtest da Estratégia




Por meio do nosso backtest inicial conseguimos os seguintes resultados para um *backtest* de junho de 2022 até setembro de 2023, período o qual conseguimos angariar os dados de headlines de notícias:

56 operações de venda, sendo que 60.13% do tempo estaremos vendidos (181 dias), 51 operações de compra, sendo que 39.87% do tempo estaremos comprados (133 dias). Obtivemos uma correlação negativa com o retorno do Mini-Dólar de -0.24, além disso obtivemos retornos acima da Taxa CDI, importante citar que consideramos que a taxa foi aplicada sobre um investimento que trouxe um rendimento diário dela, sendo que enquanto o *benchmark* rendeu 16.95%, sem contar quaisquer níveis de impostos, nossa estratégia rendeu 18.27%, sem considerar custos de *trading*, uma diferença de 1.32%, já o papel do Mini-Dólar obteve um retorno negativo de -6.91%, o que ainda reforça o potencial da nossa estratégia em gerar *alpha*. Por fim, nossa estratégia obteve um *sharpe ratio* geral de 0.53, que apesar de estar em níveis considerados médios, se demonstrou sólida na construção de retornos constantes.

Porém, críticas que devemos citar e que vão buscar ser resolvidas mediante o uso da otimização partem do pressuposto da não utilização dos diversos indicadores produzidos pela análise das notícias e, também, o fato da grande drawdown presente, principalmente na parte final da estratégia, sendo este de 6%, que no caso seria o período mais importante ao demonstrar potencial uso real da estratégia no presente.

Backtest da Estratégia



Para resolução de tais críticas, resolvemos incorporar os sentimentos positivos e negativos na nossa estratégia, note que tais indicadores são menos voláteis que o indicador total, importante citar, também, que tal indicador total não é simplesmente a média dos indicadores, mas usa de outros artifícios para seu cálculo, como demonstrado na nossa explicação do pacote Vader utilizado. Vale lembrar que eles podem melhor refletir notícias que impactam o real e impedir a tomada de posição em informações que não tenham tanto impacto ou sejam muito ambíguas. Para exemplificar tal ponto, notamos os indicadores perto de períodos importantes para a moeda nacional, como em outubro de 2022, onde, mediante vitória do candidato de esquerda Lula, cujas promessas políticas sobre gastos públicos poderiam ter efeito sobre a precificação do real, fizeram com que o indicador negativo estivesse em seu nível recorde, porém dando um efeito contrário sobre nossa estratégia. Percebemos, assim, o potencial dessas informações e seu efeito sobre períodos de grande incerteza e volatilidade.

Assim, para a incorporação de novos parâmetros e limites dos indicadores de sentimento positivo, negativo e total, tivemos a seguinte lógica:


Entraremos comprado no Mini-Dólar caso o sentimento positivo, o sentimento negativo e o sentimento total estiverem, respectivamente, acima, abaixo e acima de seus níveis no dia anterior, lembrando que realizaremos tal ordem no dia seguinte à computação de tal decisão, novamente, visando evitar o *look-ahead bias*, e entraremos vendido caso tenhamos condições contrárias às especificadas. Para conseguirmos também ter efeito sobre o *momentum* do ativo em si, incorporamos novos indicadores de médias móveis de 20 e 10 dias sobre os preços de fechamento, onde entraremos comprado se e somente se, além de tais condições antes estabelecidas, se houver um cruzamento da média móvel de menor prazo com a de maior prazo para cima, e entraremos vendido justamente caso ocorra o contrário.

Para a computação e otimização desses limites, dividimos nossos dados em teste e treino, sendo o treino usado para otimizar a estratégia, enquanto o teste reflete seu potencial na previsão dos resultados, e seu uso no mundo real. Decidimos por deixar 75% dos dados para treino e 25% para teste, visando justamente ter dados suficientes para treinarmos o modelo e ao mesmo tempo ver sua aplicabilidade no mundo real. Importante citar que usamos de tais práticas para evitar o *overfitting*, ou seja, o uso inadequado de parâmetros para previsão do futuro.



Chegamos aos seguintes resultados com a otimização:

Otimização da Estratégia


Otimizações para Estratégia com Limites dos Sentimentos Positivos e Negativo



Fazendo 8000 iterações com diversas combinações de limites, chegamos que os resultados que obtiveram o maior ganho dentro dos dados de treino, foram os quais usaram os níveis 4, 0, 8 para os sentimentos total, negativo e positivo, respectivamente, nos dando um retorno até o fim deste período de 6.41%. Apesar de percebermos que diversas outras combinações chegaram a resultados parecidos, entendemos de forma qualitativa a importância de se ter limites balanceados entre os indicadores, sendo estes os que mais se encaixavam nesse perfil. Incorporando tais dados na nossa estratégia:



Otimização da Estratégia




Com essas otimizações chegamos a tais resultados no backtest:


Uma operação de venda no início, permanecendo os 318 dias vendido, obtendo assim um retorno de 7.41% e um *Sharpe ratio* de 0.22 no período de treino, ficando abaixo do CDI. Nota-se que a incorporação de novos parâmetros como os indicadores negativo e positivo de sentimento, acabaram por atuar de modo a prejudicar a rentabilidade da estratégia no período e potencialmente ter um bias sobre a nossa posição ao ficarmos em somente uma posição em todo o período, porém, ainda percebemos oportunidades principalmente na resiliência da estratégia em conseguir dar retornos, e sua performance no período de teste recente, algo que não foi bem representado no método anterior. Assim, percebemos um modelo mais maduro e com potencial para ser usado, apresentando indicadores modestos porém potencialmente verdadeiros, considerando o cuidado na modelagem descrita para os *bias* citados, com retornos no período de teste de até 5.4% em 3 meses, ainda que esteja sobre um período de *drawdown* atualmente.

Conclusão

Acreditamos que uma das maneiras mais viáveis de conseguirmos ter insights sobre a dinâmica entre nossa estratégia e o mercado para o futuro próximo consiste em analisar seu desempenho passado ao longo dos anos, visando determinar se o algoritmo em questão gerou resultados satisfatórios ao longo do tempo para justificar o seu uso. Pela análise sentimental do Vader, traçamos o sentimento de mercado do dólar ao longo do tempo, concluindo que independente do cenário de sentimento do ativo, nosso método quantitativo conseguiu manter-se rentável graças a sua aplicação eficiente das posições de long e short.



Calculamos a correlação dos retornos de nossa estratégia com as de outros ativos que consideramos relevantes. Observamos que ela mantém uma postura neutra em relação a dos comparativos. Essa desconexão com os índices é um dos argumentos que justificam sua lucratividade, pois não só consegue mitigar os riscos contra às quedas do mercado, como também aumenta a probabilidade de gerar alpha, visto que a estratégia não está seguindo as tendências de mercado.



Conclusão

Para conseguirmos fazer uma análise completa, é de extrema importância destacar tanto o riscos da nossa estratégia. Através do backtest realizado, percebemos que o maior número de dias de perdas e ganhos seguidos foi de 6 dias. A média da volatilidade do ativo durante o período foi de aproximadamente 15%.

Nossa estratégia obteve uma rentabilidade melhor quando comparada ao CDI. Além disso, em momentos de incerteza no mercado, onde há uma ampla disseminação de notícias tendenciosas, nossa estratégia chegou a nos proteger contra movimentos especulativos e ainda por cima gerar alpha. Isso pode ser evidenciado no período de início do governo Lula, quando muitas notícias especulativas influenciaram investidores a tomar decisões enviesadas, e nesse momento obtivemos os melhores retornos. Por meio de nossa análise quantitativa, conseguimos determinar que, usando o CVaR, no pior dos cenários, há 95% de probabilidade de perda de apenas 2%, demonstrando a excelente capacidade de segurança da nossa estratégia. Porém, devido ao alto máximo drawdown, acreditamos que ela apresenta maior robustez quando utilizada em um intervalo de tempo superior a 1 ano, assim, garantindo o melhor retorno possível sem prejudicar a segurança da estratégia.

Percebemos então a possibilidade de geração de *alpha* com as informações sobre notícias, abrindo espaço não só para o desenvolvimento de novos modelos e *insights*, mas, também, o aprimoramento de nossas estratégias, para uma posterior utilização no mercado real.

Referências Bibliográficas

- ¹ Untara, Toto S., Titi L. – Global Management Conference – Bali, Indonesia, NEWS EFFECTS: GOOD VS. BAD NEWS ON EXCHANGE RATES, 2010
- ² Laakkonen, Helinä, The Impact of Macroeconomic News on Exchange Rate Volatility (July 12, 2004). Bank of Finland Discussion Paper No. 24/2004
- ³ Admati, A. – Pfleiderer, P. (1988) A theory of Intraday Patterns: Volume and Price Variability. The Review of Financial Studies, Vol. 1, 3–40
- ⁴ Damodaran, A. (1985) Economic Events, Information Structure, and the Return-generating Process. The Journal of Financial and Quantitative Analysis, Vol. 20, No. 4.
- ⁵ Veronesi, P. (1999) Stock Market Overreaction to Bad News in Good Times: A Rational Expectations Equilibrium Model. The Review of Financial Studies, Vol. 12, 975–1007.
- ⁶ Galati, G., & Ho, C. (2001). Macroeconomic news and the euro/dollar exchange rate. [Www.bis.org. https://www.bis.org/publ/work105.htm](http://www.bis.org/publ/work105.htm)
- Fontes Usadas nas Notícias:

Fontes	
NS:RTRS	3707
NS:PUBT	130
NS:ESLQ	54
NS:LSE	48
NS:CNW	36
NS:PRN	24
NS:CMNW	20
NS:IFR	18
NS:FCH	18
NS:XINHUN	12
NS:ZACKSC	12

- vaderSentiment python – Documentation
- CHAN, Ernest P. – Quantitative Trading
- PRADO, Marco López de – Advances in Financial Machine Learning